



工程计算方法

课程总结

教师：肖依永 | 刘杰 | 王洵 | 周晟瀚

可靠性与系统工程学院



第 1 章

误差和有效数字

1、误差的来源

客观存在、无法消除的

- 模型误差
- 观测误差


计算方法和过程引入的

- 截断误差
- 舍入误差

2、误差的度量

- 绝对误差
- 绝对误差限
- 相对误差
- 相对误差限

公式内准确值无法获取



3、有效数字

➤ 如果近似值 x 的误差限是其某一位上的半个单位，且该位直到 x 的第1位非零数字一共有 n 位，则称近似值 x 有 n 位有效数字。

4、机器数系

5、误差的危害与传递

6、误差危害防止

- 使用数值稳定的计算公式
- 防止大数“吃掉”小数
- 尽量避免两相近数相减
- 简化计算步骤，减少运算次数
- 尽量避免用绝对值很大的数作乘数

1.2.2 绝对误差与绝对误差限

➤绝对误差

设 x 是准确值 x^* 的近似值，称 e 是近似值 x 的绝对误差。简称误差。

$$e = x^* - x$$

➤绝对误差限

通常准确值 x^* 未知，故绝对误差很难得到。但可以估计出 $|e|$ 不超过某个正数 ε ，称 ε 为绝对误差限。简称误差限。

$$|e| = |x^* - x| \leq \varepsilon \quad x^* = x \pm \varepsilon \quad x - \varepsilon \leq x^* \leq x + \varepsilon$$

1.2.3 相对误差与相对误差限

绝对误差的大小，在许多情况下还不能完全刻划一个近似值的准确程度。例如测量1000米和1米两个长度，若它们的绝对误差都是1厘米，显然前者的测量比较准确。由此可见一个近似值的精确程度，除了要考虑绝对误差外，还需考虑测量量本身的大小。

➤ 相对误差

设 x^* 是准确值， x 是近似值，称下式为近似值 x 的相对误差。

$$e_r = \frac{e}{x^*} = \frac{x^* - x}{x^*}$$

1.2.3 相对误差与相对误差限

实际计算中真值 x^* 通常难以求得，因此通常用下式作为相对误差。

$$\bar{e}_r = \frac{e}{x} = \frac{x^* - x}{x}$$

➤ 相对误差限

计算相对误差与计算绝对误差具有相同的困难，因此通常只考虑相对误差限 ε_r 。

$$|e_r| \leq \varepsilon_r \quad \text{或} \quad |\bar{e}_r| \leq \varepsilon_r$$

相对误差和相对误差限是无量纲的，但绝对误差和绝对误差限是有量纲的。

1.2.5 数据误差的影响

数值运算中由于所给数据的误差必然引起函数值的误差，这种数据误差的影响比较复杂，一般采用泰勒级数展开的方法来估计。如计算 $y = f(x_1, x_2)$ 的值，设给定数据 x_1 和 x_2 是近似数，则由此计算得到的 y 也只是近似值，现在来研究 y 的绝对误差和相对误差。

x_1^*, x_2^* 是准确值 $y^* = f(x_1^*, x_2^*)$ 是函数准确值

x_1, x_2 是近似值 $y = f(x_1, x_2)$ 是函数近似值

$e(y) = y^* - y = f(x_1^*, x_2^*) - f(x_1, x_2)$ 是 y 的误差

可以利用一阶泰勒多项式进行误差的估计

1.2.5 数据误差的影响

$$f(x_1^*, x_2^*) \approx f(x_1, x_2) + \frac{\partial f(x_1, x_2)}{\partial x_1} (x_1^* - x_1) + \frac{\partial f(x_1, x_2)}{\partial x_2} (x_2^* - x_2)$$

$$e(y) = y^* - y \approx \frac{\partial f(x_1, x_2)}{\partial x_1} (x_1^* - x_1) + \frac{\partial f(x_1, x_2)}{\partial x_2} (x_2^* - x_2)$$

$$e(y) \approx \frac{\partial f(x_1, x_2)}{\partial x_1} e(x_1) + \frac{\partial f(x_1, x_2)}{\partial x_2} e(x_2)$$

进而可得

$$e_r(y) = \frac{\partial f(x_1, x_2)}{\partial x_1} \frac{x_1}{y} e_r(x_1) + \frac{\partial f(x_1, x_2)}{\partial x_2} \frac{x_2}{y} e_r(x_2)$$

1.2.5 数据误差的影响

$$e_r(y) \approx \frac{\partial f(x_1, x_2)}{\partial x_1} \frac{x_1}{y} e_r(x_1) + \frac{\partial f(x_1, x_2)}{\partial x_2} \frac{x_2}{y} e_r(x_2)$$

两数和、差、积、商的相对误差估计：

$$e_r(x_1 + x_2) \approx \frac{x_1}{x_1 + x_2} e_r(x_1) + \frac{x_2}{x_1 + x_2} e_r(x_2)$$

$$e_r(x_1 - x_2) \approx \frac{x_1}{x_1 - x_2} e_r(x_1) - \frac{x_2}{x_1 - x_2} e_r(x_2)$$

$$e_r(x_1 x_2) \approx e_r(x_1) + e_r(x_2)$$

$$e_r\left(\frac{x_1}{x_2}\right) \approx e_r(x_1) - e_r(x_2) \quad x_2 \neq 0$$



第 2 章

非线性方程的数值解法

非线性方程的数值解法

$$f(x) = 0$$

第一类是**区间收缩法**。

➤ 二分法

确定初始含根区间

- 零点存在定理
- 搜索法
- 作图法

事前误差控制

$$k > \lg \frac{b-a}{\varepsilon} / \lg 2 - 1 \Rightarrow K = \lceil \lg \frac{b-a}{\varepsilon} / \lg 2 \rceil$$

第二类是**迭代法**。 $x_{k+1} = g(x_k)$

➤ 简单迭代法

➤ 牛顿法

➤ 弦截法

收敛性

- 李普希兹连续
- 非局部收敛定理

事前误差控制

$$K = \left\lceil \frac{1}{|\ln L|} \left(\ln \frac{|x_1 - x_0|}{1 - L} - \ln \varepsilon \right) \right\rceil + 1$$

泰勒展开式

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

$$\begin{cases} x_{k+1} = x_k - \frac{f(x_k)}{f(x_k) - f(x_{k-1})} (x_k - x_{k-1}) & (k = 0, 1, \dots) \\ x_0, x_{-1} \end{cases}$$

问题： 求解 $f(x) = 0$

数值计算方法主要分为两大类。

第一类是区间收缩法。

- (1) 确定初始含根区间
- (2) 收缩含根区间

第二类是迭代法。

- (1) 选定根的初始近似值
- (2) 按某种原则生成收敛于根的近似点列

2.2 一般迭代法

— 迭代法的算法思想

$$\text{对 } f(x)=0 \quad (1)$$

迭代法的算法思想为：

(A) 把 (1) 等价变换为如下形式

$$x = g(x) \quad (2)$$

当 $x^* = g(x^*)$, x^* 称为 $g(x)$ 的不动点

(B) 建立迭代格式

$$\mathbf{x}_{k+1} = \mathbf{g}(\mathbf{x}_k) \quad (3)$$

(C) 适当选取初始值 $\mathbf{x}_0$, 递推计算出所需的解。

其中: $g(x)$ —— 迭代函数

$x_{k+1} = g(x_k)$ —— 迭代格式

—— 称为简单迭代法

定理2.2 (非局部收敛定理) 如果 $g(x)$ 在 $[a,b]$ 上连续可微且以下条件满足:

(1) 若 $x \in [a,b]$, 则 $g(x) \in [a,b]$

(2) 对 $\forall x \in [a,b], |g'(x)| \leq L < 1$

那么,对 $\forall x \in [a,b], x_{k+1} = g(x_k)$ 的解序列 $\{x_k\}$ 收敛于 x^* .

命题2.2 若在区间 $[a,b]$ 内 $|g'[x]| \geq 1$, 则对任何 $x_0 \in [a,b]$, 迭代格式 $x_{k+1} = g(x_k)$ 不收敛。

2.3 牛顿迭代法

一、 牛顿迭代公式的构造

设 $f(x)$ 在其零点 x^* 附近连续可微, 已知 x_k 为 x^* 的第 k 次近似值, 则

$$\begin{aligned} f(x) &= f(x_k) + f'(x_k)(x - x_k) + O((x - x_k)^2) \\ &\approx f(x_k) + f'(x_k)(x - x_k) \stackrel{\Delta}{=} P_1(x) \end{aligned}$$

取 $P_1(x) = 0$ 的根作为 x^* 的第 $k+1$ 次近似值 x_{k+1}


解得

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \quad (2-12)$$

牛顿迭代法

其迭代函数为

$$g(x) = x - \frac{f(x)}{f'(x)} \quad (2-13)$$



几何意义：过点 $P(x_k, f(x_k))$ 作函数 $y=f(x)$ 的切线 l ：

$$y = f(x_k) + f'(x_k)(x - x_k)$$

以切线 l 与 x 轴的交点 x_{k+1} 作为 x^* 的新近似值

2.4 弦截法

计算思想是：若已知 x^* 的两个近似值 x_k 和 x_{k-1} ，则以 $f(x)$ 在 x_k 与 x_{k-1} 之间的平均变化率(差商) $\frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$ 近似代替 $f'(x_k)$ ，据此把牛顿迭代法修改为


$$\begin{cases} x_{k+1} = x_k - \frac{f(x_k)}{f(x_k) - f(x_{k-1})} (x_k - x_{k-1}) \\ x_0, x_{-1} \end{cases} \quad (k = 0, 1, \dots)$$

弦截法

几何意义是以过 $P(x_k, f(x_k))$ 和 $Q(x_{k-1}, f(x_{k-1}))$ 两点做曲线 $y = f(x)$ 的弦线 l ：

$$y = f(x_k) + \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}} (x - x_k)$$

以 l 与 x 轴的交点 x_{k+1} 作为的新近似值





第 3 章

线性方程组的数值解法

$f(x) = 0$ 非线性方程的数值解法

第一类是区间收缩法。

- 二分法

第二类是迭代法。

$$\mathbf{x}_{k+1} = \mathbf{g}(\mathbf{x}_k)$$

- 简单迭代法
- 牛顿法
- 弦截法

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \frac{f(\mathbf{x}_k)}{f'(\mathbf{x}_k)}$$

$$\begin{cases} \mathbf{x}_{k+1} = \mathbf{x}_k - \frac{f(\mathbf{x}_k)}{f(\mathbf{x}_k) - f(\mathbf{x}_{k-1})}(\mathbf{x}_k - \mathbf{x}_{k-1}) & (k = 0, 1, \dots) \\ \mathbf{x}_0, \mathbf{x}_{-1} \end{cases}$$

线性方程组的数值解法 $Ax = b$

第一类是直接解法。

- 高斯消去法

$$D = \begin{pmatrix} a_{11} & & \\ & a_{22} & \\ & & \ddots \\ & & & a_{nn} \end{pmatrix} \quad \mathbf{g} = \begin{pmatrix} g_1 \\ g_2 \\ \dots \\ g_n \end{pmatrix}$$

第二类是迭代法。

$$\mathbf{x}^{(k+1)} = M\mathbf{x}^{(k)} + \mathbf{f}$$

- 简单 (Jacobi) 迭代法
- Gauss-Seidel 迭代法
- 松弛法

$$M = B_1 = (I - L)^{-1}U, \quad \mathbf{f} = (I - L)^{-1}\mathbf{g}$$

$$M = B_\omega = (I - \omega L)^{-1}((1 - \omega)I + \omega U), \quad \mathbf{f} = \omega(I - \omega L)^{-1}\mathbf{g}$$

$$M = B = D^{-1}(D - A) = I - D^{-1}A, \quad \mathbf{f} = \mathbf{g} = D^{-1}\mathbf{b}$$

泰勒展开式



第 4 章

非线性方程组的数值解法

$$\mathbf{F}(\mathbf{x}) = \begin{pmatrix} f_1(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{pmatrix} = \mathbf{0}$$

$$\mathbf{x}^{(k+1)} = \Phi(\mathbf{x}^{(k)})$$

➤ 简单 (Jacobi) 迭代法

➤ Gauss-Seidel 迭代法

➤ 牛顿迭代法
$$\begin{cases} \nabla F(\mathbf{x}^{(k)}) \Delta \mathbf{x}^{(k)} = -F(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}^{(k)} \end{cases}$$

泰勒展开式

➤ 最速下降法
$$\varphi(\mathbf{x}) = \frac{1}{2} \mathbf{F}(\mathbf{x})^T \mathbf{F}(\mathbf{x}) = \frac{1}{2} [f_1(\mathbf{x})^2 + f_2(\mathbf{x})^2 + \dots + f_m(\mathbf{x})^2]$$

$$\mathbf{p}^{(k)} = -\nabla \varphi(\mathbf{x}^{(k)}) = -\mathbf{F}(\mathbf{x})^T \nabla F(\mathbf{x})$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \frac{\varphi(\mathbf{x}^{(k)})}{(\mathbf{p}^{(k)})^T \mathbf{p}^{(k)}} \mathbf{p}^{(k)} \quad k = 0, 1, 2, \dots$$

二、简单迭代法及其收敛性

将 $F(\mathbf{x}) = 0$ 写成便于迭代的形式 $\mathbf{x} = \Phi(\mathbf{x})$

由迭代格式 $\mathbf{x}^{(k+1)} = \Phi(\mathbf{x}^{(k)})$

产生迭代序列 $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(k)}, \dots$

若 $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*$, 则 $\mathbf{x}^* = \Phi(\mathbf{x}^*)$, 即 $F(\mathbf{x}^*) = 0$

称 $\mathbf{x}^*$ 为映射 $\Phi(\mathbf{x})$ 的不动点。

研究非线性方程组解的存在唯一性问题可转化为研究不动点的存在唯一性。

4.2 非线性方程组的Newton型算法

迭代格式推导:

以两个方程为例推导
$$\begin{cases} f_1(x_1, x_2) = 0 \\ f_2(x_1, x_2) = 0 \end{cases} \Leftrightarrow F(x) = 0$$

已知第 k 次近似值 $x^{(k)} = (x_1^{(k)}, x_2^{(k)})^T$, 在 $x^{(k)}$ 作泰劳展开

$$\begin{aligned} f_1(x_1, x_2) &\approx f_1(x_1^{(k)}, x_2^{(k)}) + \frac{\partial f_1}{\partial x_1}(x_1 - x_1^{(k)}) + \frac{\partial f_1}{\partial x_2}(x_2 - x_2^{(k)}) \\ &= l_1(x_1, x_2) \end{aligned}$$

$$\begin{aligned} f_2(x_1, x_2) &\approx f_2(x_1^{(k)}, x_2^{(k)}) + \frac{\partial f_2}{\partial x_1}(x_1 - x_1^{(k)}) + \frac{\partial f_2}{\partial x_2}(x_2 - x_2^{(k)}) \\ &= l_2(x_1, x_2) \end{aligned}$$

$$L(\mathbf{x}) = \begin{bmatrix} l_1(x_1, x_2) \\ l_2(x_1, x_2) \end{bmatrix}, \text{令 } L(\mathbf{x}^{(k+1)}) = \mathbf{0}, \text{ 得到}$$

$$\begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix} \begin{bmatrix} x_1^{(k+1)} - x_1^{(k)} \\ x_2^{(k+1)} - x_2^{(k)} \end{bmatrix} = - \begin{bmatrix} f_1(x_1^{(k)}, x_2^{(k)}) \\ f_2(x_1^{(k)}, x_2^{(k)}) \end{bmatrix}$$

$$\text{记 } \Delta \mathbf{x}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} = \begin{bmatrix} x_1^{(k+1)} - x_1^{(k)} \\ x_2^{(k+1)} - x_2^{(k)} \end{bmatrix}, \quad \nabla F(\mathbf{x}^{(k)}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix}$$

得 $Newton$ 迭代格式

$$\begin{cases} \nabla F(\mathbf{x}^{(k)}) \Delta \mathbf{x}^{(k)} = -F(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}^{(k)} \end{cases}$$

迭代终止标准为 $\max_{1 \leq i \leq n} |\Delta x_i^{(k)}| < \varepsilon$ 或 $\|F(\mathbf{x}^{(k+1)})\| < \varepsilon$

雅可比矩阵求逆得到：

*Newton*迭代格式：

$$\begin{cases} \Delta \mathbf{x}^{(k)} = -(\nabla F(\mathbf{x}^{(k)}))^{-1} F(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}^{(k)} \end{cases} \quad k = 0, 1, 2, \dots$$

迭代终止标准为 $\max_{1 \leq i \leq n} |\Delta x_i^{(k)}| < \varepsilon$ 或 $\|F(\mathbf{x}^{(k+1)})\| < \varepsilon$

牛顿法求解非线性方程组 $F(x)=0$ 的算法步骤:

$$\begin{cases} \Delta \mathbf{x}^{(k)} = -(\nabla F(\mathbf{x}^{(k)}))^{-1} F(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}^{(k)} \end{cases} \quad k = 0, 1, 2, \dots$$

算法步骤:

第 0 步: 设定初始解 $\mathbf{x}^{(0)} = [1, 1, 1]$, 令 $k \leftarrow 0$;

第 1 步: 计算 $F(\mathbf{x}^{(k)})$, 判断: 如果 $\|F(\mathbf{x}^{(k)})\|$ 满足精度要求, 则转第 6 步;

第 2 步: 计算 $\nabla F(\mathbf{x}^{(k)})$;

第 3 步: 计算 $(\nabla F(\mathbf{x}^{(k)}))^{-1}$;

第 4 步: 计算

$$\Delta \mathbf{x}^{(k)} = -(\nabla F(\mathbf{x}^{(k)}))^{-1} F(\mathbf{x}^{(k)}),$$

判断: 如果 $\|\nabla \mathbf{x}^{(k)}\|$ 满足精度要求, 则转第 6 步;

第 5 步: 令 $\mathbf{x}^{(k+1)} \leftarrow \mathbf{x}^{(k)} + \Delta \mathbf{x}^{(k)}$, $k \leftarrow k + 1$; 转第 1 步。

第 6 步: 计算结束, 输出结果。



第5章

数值插值方法与计算实验

- 实际工作中，很难找到 $f(x)$ 的具体表达式，只能观测到一些离散数据
- 或者 $f(x)$ 过于复杂而不易运算

x_i	x_0	x_1	x_2	x_3	x_4
y_i	y_0	y_1	y_2	y_3	y_4

思路：

用简单函数为离散数组建立模型或为复杂函数建立逼近

➤ 用简单函数为离散数组建立模型或为复杂函数建立逼近需要解决三个问题

- ① 选定简单函数的类型。通常是选取一组线性无关的简单函数 $\varphi_0, \varphi_1, \dots, \varphi_n$ ，利用它们形成线性空间

$$\Phi = \text{span} \{ \varphi_0, \varphi_1, \varphi_2, \dots, \varphi_n \}$$

利用形如

$$P(x) = a_0 \varphi_0 + a_1 \varphi_1 + \dots + a_n \varphi_n \quad (5.1)$$

的函数产生模型和进行逼近。问题归结为求 $a_0, a_1, \dots, a_n$ ，称 $\varphi_0, \varphi_1, \dots, \varphi_n$ 为**基函数**。

- ② 建立关于模型或逼近的目标，目标决定(5.1)式中 φ 必须满足的条件。条件分插值型和逼近型两类
- ③ 建立算法并作出理论分析

x_i	x_0	x_1	x_2	x_3	x_4
y_i	y_0	y_1	y_2	y_3	y_4

- 给定未知函数 $f(x)$ 的一个数表 $y_i=f(x_i)$ ($i=0,1,\dots,n$)，求某个简单的函数 $\phi(x)$ ，来逼近函数 $f(x)$ ，并且使 $\phi(x_i)=y_i$ ，这种方法称为插值法
- 具体有很多种插值法，其中以拉格朗日(Lagrange)插值和牛顿(Newton)插值为代表的多项式插值最有特点，常用的插值还有Hermit插值，分段插值和样条插值
- 插值的任务就是由已知的观测点，为物理量(未知量)建立一个简单的、连续的解析模型，以便能根据该模型推测该物理量在非观测点处的特性

定义： 设精确函数 $y = f(x)$ 在区间 $[a, b]$ 有定义，且已知在 $a \leq x_0 < x_1 < x_2 < \dots < x_n \leq b$ 上的值为 $y_0, y_1, y_2, \dots, y_n$ ，若存在一个简单的函数 $\phi(x)$ ，来逼近函数 $f(x)$ ，并且使

$$\phi(x_i) = y_i, \quad (i=0, 1, 2, \dots, n) \quad *$$

成立。则称 $\phi(x)$ 为 $f(x)$ 的插值函数，称 $x_0, x_1, x_2, \dots, x_n$ 为插值节点，区间 $[a, b]$ 为插值区间， $(*)$ 式为插值条件。

Lagrange插值

类似线性插值与抛物插值，我们用插值基函数的方法来构造 $P_n(x)$ 。 $l_0(x)$, $l_1(x), \dots, l_n(x)$ 为 $n+1$ 个 n 次多项式， $P_n(x)$ 可表示为它们的线性组合

$$P_n(x) = l_0(x)y_0 + l_1(x)y_1 + l_2(x)y_2 + \cdots + l_n(x)y_n = \sum_{k=0}^n l_k(x)y_k$$

$$l_i(x) = \frac{(x-x_0)\cdots(x-x_{i-1})(x-x_{i+1})\cdots(x-x_n)}{(x_i-x_0)\cdots(x_i-x_{i-1})(x_i-x_{i+1})\cdots(x_i-x_n)} = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x-x_j}{x_i-x_j}$$

$$R_n(x) = \frac{1}{(n+1)!} f^{(n+1)}(\xi)(x-x_0)(x-x_1)(x-x_2)\cdots(x-x_n)$$

Newton插值

定义： 设函数 $f(x)$ 在 $n+1$ 个相异的点 $x_0, x_1, x_2, \dots, x_n$ 上的函数值分别为 $f(x_0), f(x_1), f(x_2), \dots, f(x_n)$, 称

$$\varphi_0(x) \equiv 1$$

$$\varphi_k(x) = (x - x_{k-1})\varphi_{k-1}(x) = (x - x_0)(x - x_1)\cdots(x - x_{k-1})$$

$$k = 1, 2, \dots, n$$

为Newton插值在 $x_0, x_1, x_2, \dots, x_n$ 上的基函数

Newton插值目的是构造次数 $\leq n$ 的多项式

$$P_n(x) = a_0\varphi_0 + a_1\varphi_1 + \cdots + a_n\varphi_n$$

Newton插值

$$a_n = f[x_0, \cdots, x_n]$$

$$\begin{aligned} P_n(x) = & f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) \\ & + \cdots + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \cdots (x - x_{n-1}) \end{aligned}$$

$$\begin{aligned} R_n(x) &= f(x) - P_n(x) \\ &= f[x_0, x_1, \cdots, x_n, x](x - x_0) \cdots (x - x_n) \end{aligned}$$

等距节点插值

由于 $x_k = x_0 + kh$, 令 $x = x_0 + th$, $t \in [0, n]$ 则上式成为

$$f(x) = f(x_0) + \Delta y_0 t + \frac{1}{2!} \Delta^2 y_0 t(t-1) + \cdots + \frac{1}{n!} \Delta^n y_0 t(t-1) \cdots (t-n+1) + R_n(x)$$

$$R_n(x) = \frac{t(t-1) \cdots (t-n)}{(n+1)!} h^{n+1} f^{(n+1)}(\xi) \quad \xi \in [x_0, x_n]$$

上式称为**Newton前插值公式**

$$f(x) = f(x_0) + \nabla y_0 t + \frac{1}{2!} \nabla^2 y_0 t(t+1) + \cdots + \frac{1}{n!} \nabla^n y_0 t(t+1) \cdots (t+n-1) + R_n(x)$$

$$R_n(x) = \frac{t(t+1) \cdots (t+n)}{(n+1)!} h^{n+1} f^{(n+1)}(\xi) \quad \xi \in [x_0, x_n]$$

上式称为**Newton后插值公式**

分段低次插值

$$P(x) = y_i \frac{x - x_{i+1}}{x_i - x_{i+1}} + y_{i+1} \frac{x - x_i}{x_{i+1} - x_i} \quad x_i \leq x \leq x_{i+1}$$

分段线性插值的余项:

$$R_n(x) = \frac{1}{(n+1)!} f^{(n+1)}(\xi)(x-x_0)(x-x_1)(x-x_2)\cdots(x-x_n)$$

定理: 设 $f(x)$ 在 $[a,b]$ 上有二阶连续导数 $f''(x)$, 且 $|f''(x)| \leq m$,

记: $h = \max |x_{i+1} - x_i|$, 就有估计:

$$|f(x) - P(x)| = |R(x)| \leq mh^2/8, \quad x \in [a,b]$$

注意到 h 随分段增多而减少, 因此用分段法提高精度是很好的途径.

分段低次插值

选取跟节点 x 最近的三个节点 x_{i-1}, x_i, x_{i+1} 进行二次插值，即在区间 $[x_{i-1}, x_{i+1}]$ 上取 $P(x)$ 如下式。这种分段低次插值叫分段二次插值，在几何上就是用分段抛物线代替 $y = f(x)$ ，又称分段抛物插值

$$f(x) \approx P_2(x) = \sum_{k=i-1}^{i+1} \left(\prod_{\substack{j=i-1 \\ j \neq k}}^{i+1} \frac{x - x_j}{x_k - x_j} \right) y_k$$

定义： $f(x)$ 是区间 $[a, b]$ 上 $n+1$ 个互异节点 $a = x_0 < x_1 < x_2 < \dots < x_{n-1} < x_n = b$, 函数 $f(x)$ 在节点上有

$$f(x_i) = y_i \quad f'(x_i) = y'_i \quad i=0,1,2,\dots,n$$

要求一个插值多项式满足条件

$$H(x_i) = y_i \quad H'(x_i) = y'_i \quad i=0,1,2,\dots,n$$

若 $H(x)$ 存在, 则称为函数 $f(x)$ 的 **Hermite插值多项式**。

因为 $H(x)$ 是一个次数不高于 $2n+1$ 次的多项式, 常记为 $H_{2n+1}(x)$

$$H_{2n+1}(x) = a_0 + a_1x + a_2x^2 + \dots + a_{2n+1}x^{2n+1}$$

定理： 满足上述插值条件且次数不大于 $2n+1$ 的多项式是唯一的。

Hermite插值

$$H_{2n+1}(x) = \sum_{i=0}^n h_i(x) f(x_i) + \sum_{i=0}^n g_i(x) f'(x_i)$$

$$H_{2n+1}(x) = \sum_{i=0}^n f(x_i) \left[1 - 2(x - x_i) \sum_{\substack{j=0 \\ j \neq i}}^n \frac{1}{x_i - x_j} \right] (l_i(x))^2 + \sum_{i=0}^n f'(x_i) (x - x_i) (l_i(x))^2$$

$$R_{2n+1}(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} [(x - x_0)(x - x_1) \cdots (x - x_n)]^2$$

样条插值

定义： 设 $f(x)$ 是区间 $[a,b]$ 上的一个连续可微函数,在区间 $[a,b]$ 上给定一组基点:

$$a=x_0<x_1<x_2<\cdots<x_n=b$$

设函数 $S(x)$ 满足条件

- (1) $S(x)$ 在每个子区间 $[x_i, x_{i+1}]$ ($i = 0, 1, 2, \cdots, n-1$)上是次数不超过 k 的多项式;**
- (2) $S(x)$ 在区间 $[a,b]$ 上有 $k-1$ 阶连续导数;**

则称 $S(x)$ 是定义在 $[a,b]$ 上的 k 次样条函数。 $x_0, x_1, x_2, \cdots, x_n$ 称为**样条节点**,其中 $x_1, \cdots, x_{n-1}$ 称为**内节点**, x_0, x_n 称为**边界节点**。当 $k=3$ 时, 便成为最常用的**三次样条函数**

样条插值

设 $y = f(x)$ 在 $x_0, x_1, x_2, \cdots, x_n$ 的值为 $y_0, y_1, y_2, \cdots, y_n$, 若函数 $S(x)$ 满足下列条件

(1) 在每个区间 $[x_i, x_{i+1}]$ 上为三次多项式

$$(2) S(x_i) = f(x_i) = y_i, \quad i = 0, 1, 2, \cdots, n \quad (5.13)$$

$$(3) S'(x_i^-) = S'(x_i^+) \quad i = 1, 2, \cdots, n-1$$

则称 $S(x)$ 为函数 $f(x)$ 的**三次样条插值函数**, 简称**三次样条**。

样条插值

$$\begin{cases} \mu_i = \frac{h_i}{h_{i-1} + h_i}, & \lambda_i = 1 - \mu_i \\ d_i = \frac{6}{h_{i-1} + h_i} \left(\frac{y_{i+1} - y_i}{h_i} - \frac{y_i - y_{i-1}}{h_{i-1}} \right) \end{cases} \quad (i=1, 2, \dots, n-1)$$

第1类边界条件: $S''(x_0) = M_0, S''(x_n) = M_n$

设 $\lambda_0 = 0, d_0 = 2y_0'', \mu_n = 0, d_n = 2y_n''$ (为凑下面表达形式)

$$\begin{bmatrix} 2 & \lambda_0 & & \\ \mu_1 & 2 & \lambda_1 & \\ & \dots & \dots & \dots \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & \mu_n & 2 \end{bmatrix} \begin{bmatrix} M_0 \\ M_1 \\ \dots \\ M_{n-1} \\ M_n \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ \dots \\ d_{n-1} \\ d_n \end{bmatrix}$$

特别地, $M_0 = M_n = 0$ 称为**自由边界**, 对应的样条函数称为**自然样条**

样条插值

$$\begin{cases} \mu_i = \frac{h_i}{h_{i-1} + h_i}, & \lambda_i = 1 - \mu_i \\ d_i = \frac{6}{h_{i-1} + h_i} \left(\frac{y_{i+1} - y_i}{h_i} - \frac{y_i - y_{i-1}}{h_{i-1}} \right) \end{cases} \quad (i=1, 2, \dots, n-1)$$

第2类边界条件: $S'(x_0) = y'_0, S'(x_n) = y'_n$

$$S'(x) = -M_0 \frac{(x_1 - x)^2}{2h_1} + M_1 \frac{(x - x_0)^2}{2h_1} + \frac{y_1 - y_0}{h_1} - \frac{M_1 - M_0}{6} h_1$$

$$2M_0 + M_1 = \frac{6}{h_1} \left(\frac{y_1 - y_0}{h_1} - y'_0 \right) = d_0$$

$$M_{n-1} + 2M_n = \frac{6}{h_n} \left(y'_n - \frac{y_{n-1} - y_n}{h_n} \right) = d_n$$

若 $\lambda_0 = 1, \mu_n = 1$, **亦有**(为凑下面表达形式)

$$\begin{bmatrix} 2 & \lambda_0 & & & \\ \mu_1 & 2 & \lambda_1 & & \\ & \dots & \dots & \dots & \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & \mu_n & 2 \end{bmatrix} \begin{bmatrix} M_0 \\ M_1 \\ \dots \\ M_{n-1} \\ M_n \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ \dots \\ d_{n-1} \\ d_n \end{bmatrix}$$

样条插值

$$\begin{cases} \mu_i = \frac{h_i}{h_{i-1} + h_i}, & \lambda_i = 1 - \mu_i \\ d_i = \frac{6}{h_{i-1} + h_i} \left(\frac{y_{i+1} - y_i}{h_i} - \frac{y_i - y_{i-1}}{h_{i-1}} \right) \end{cases} \quad (i=1, 2, \dots, n-1)$$

第3类边界条件： $f(x)$ 是周期函数，满足条件

$$S(x_0) = S(x_n), \quad S'(x_0^+) = S'(x_n^-), \quad S''(x_0^+) = S''(x_n^-)$$

$$\begin{cases} M_n = M_0 \\ \lambda_n M_1 + \mu_n M_{n-1} + 2M_n = d_n \end{cases}$$

其中 $\mu_n = \frac{h_n}{h_n + h_1}, \lambda_n = 1 - \mu_n, d_n = 6 \left(\frac{y_1 - y_0}{h_1} - \frac{y_n - y_{n-1}}{h_n} \right) (h_1 + h_n)^{-1}$

有

$$\begin{bmatrix} 2 & \lambda_1 & & \mu_1 \\ \mu_2 & 2 & \lambda_2 & \\ & \dots & \dots & \dots \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ \lambda_n & & & \mu_n & 2 \end{bmatrix} \begin{bmatrix} M_1 \\ M_2 \\ \dots \\ M_{n-1} \\ M_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ \dots \\ d_{n-1} \\ d_n \end{bmatrix}$$

抛物插值

[例]某人15岁时身高是150cm, 16岁时身高是160cm, 18岁时身高是170cm, 17岁时的身高大约是多少?

解: $n = 1$

$$\Rightarrow P_1(x) = \frac{x-18}{16-18} \times 160 + \frac{x-16}{18-16} \times 170$$

$$\Rightarrow P_1(17) = \frac{17-18}{16-18} \times 160 + \frac{17-16}{18-16} \times 170 = 165$$

$$\Rightarrow p_1(x) = \frac{x-18}{15-18} \times 150 + \frac{x-15}{18-15} \times 170$$

$$\Rightarrow p_1(17) = \frac{17-18}{15-18} \times 150 + \frac{17-15}{18-15} \times 170 = 163.33$$

抛物插值

$$n = 2$$

$$P_2(x) = \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)}y_0 + \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)}y_1 + \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)}y_2$$

$$\begin{aligned} P_2(17) &= \frac{(17-16)(17-18)}{(15-18)(15-16)} \times 150 + \frac{(17-15)(17-18)}{(16-15)(16-18)} \times 160 \\ &\quad + \frac{(17-15)(17-16)}{(18-15)(18-16)} \times 170 \\ &= 166.67 \end{aligned}$$

➤ 插值区间和结点的选择影响插值结果



第6章

函数的数值拟合

曲线拟合

设在直角坐标系中给定 $m + 1$ 对数据 (x_i, y_i) , $i = 0, 1, \dots, m$, 其中 $a = x_0 < x_1 < x_2 < \dots < x_m = b$ 。又选定 $n + 1$ 个在区间 $[a, b]$ 上连续且线性无关的基函数 $\varphi_j(x)$, $j = 0, 1, \dots, n$, 其中 $n \leq m$, 问题是要在曲线族 $P(x) = a_0 \varphi_0(x) + a_1 \varphi_1(x) + \dots + a_n \varphi_n(x)$ 中寻找一条曲线, 在某种原则下对给定数据拟合的最好。

$$\text{若曲线 } P^*(x) = \sum_{j=0}^n a_j^* \varphi_j(x) \text{ 使得}$$
$$\sum_{i=0}^m \left[\sum_{j=0}^n a_j^* \varphi_j(x_i) - y_i \right]^2 = \min_{\{a_j\}} \sum_{i=0}^m \left[\sum_{j=0}^n a_j \varphi_j(x_i) - y_i \right]^2$$

成立, 则称曲线 $P^*(x)$ 为按最小二乘原则确定的对已知数据的拟合曲线。

∴ 可得矩阵

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \cdots & \cdots & \cdots & \cdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \cdots \\ a_n \end{bmatrix} = \begin{bmatrix} (\varphi_0, f) \\ (\varphi_1, f) \\ \cdots \\ (\varphi_n, f) \end{bmatrix}$$

当 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$ 线性无关时存在唯一解
 $a_i (i = 0, 1, \dots, n)$

法方程组

$\Phi = P_n = \text{span}\{1, x, \dots, x^n\}$, 则相应的法方程为

$$\begin{bmatrix} \sum_{i=0}^m 1 & \sum_{i=0}^m x_i & \cdots & \sum_{i=0}^m x_i^n \\ \sum_{i=0}^m x_i & \sum_{i=0}^m x_i^2 & \cdots & \sum_{i=0}^m x_i^{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=0}^m x_i^n & \sum_{i=0}^m x_i^{n+1} & \cdots & \sum_{i=0}^m x_i^{2n} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} \sum_{i=0}^m f_i \\ \sum_{i=0}^m x_i f_i \\ \vdots \\ \sum_{i=0}^m x_i^n f_i \end{bmatrix}$$

此时 $P^*(x) = \sum_{k=0}^n a_k^* x^k$ 称为代数拟合多项式。

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m \end{cases}$$

$m > n$ 时称方程组是矛盾的或不相容的，无解。

可利用最小二乘原理求上述方程组的近似解

设残差平方和

$$I(x_1, x_2, \dots, x_n) = \sum_{k=1}^m [b_k - (a_{k1}x_1 + a_{k2}x_2 + \cdots + a_{kn}x_n)]^2$$

问题转化为：求 $(x_1, x_2, \dots, x_n)$ 使得残差平方和极小。

6.6 正交多项式的曲线拟合

问题：以幂函数为基函数时，即 $\varphi_j = x^j$ 时，当 n 较大时，如 $n > 7$ ，法方程往往是病态方程，病态将随着 n 的增大而增加。为了克服这一问题，引入**正交多项式**作为基函数。

定义：设给定点集 $\{x_i\}_{i=0}^m$ 以及各点的权系数 $\{\omega_i\}_{i=0}^m$ ，如果多项式族 $\{p_k(x)\}_{k=0}^n$ 满足

$$(p_k, p_j) = \sum_{i=0}^m \omega_i p_k(x_i) p_j(x_i) = \begin{cases} 0, & k \neq j \\ A_k \neq 0, & k = j \end{cases}$$

则称 $\{p_k(x)\}_{k=0}^n$ 为关于点集 $\{x_i\}_{i=0}^m$ 的带权 $\{\omega_i\}_{i=0}^m$ 正交的多项式族。

正交多项式族的构造

给定 $(x_i, f(x_i))$ 和权系数 ω_i ，如何构造正交多项式族 $\{p_k(x)\}_{k=0}^n$

$$\text{令 } \begin{cases} p_0(x) = 1 \\ p_1(x) = (x - \alpha_0)p_0(x) = x - \alpha_0 \\ p_{k+1}(x) = (x - \alpha_k)p_k(x) - \beta_{k-1}p_{k-1}(x) \quad (k = 1, \dots, n-1) \end{cases}$$

$$\text{其中 } \begin{cases} \alpha_k = (xp_k, p_k)/(p_k, p_k) \quad (k = 0, 1, \dots, n-1) \\ \beta_{k-1} = (p_k, p_k)/(p_{k-1}, p_{k-1}) \quad (k = 1, 2, \dots, n-1) \end{cases}$$

可以证明 $\{p_k(x)\}_{k=0}^n$ 是关于点集 $\{x_i\}_{i=0}^m$ 的带权 $\{\omega_i\}_{i=0}^m$ 的正交的多项式族。

正交多项式族的构造

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \cdots & \cdots & \cdots & \cdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \cdots \\ a_n \end{bmatrix} = \begin{bmatrix} (\varphi_0, f) \\ (\varphi_1, f) \\ \cdots \\ (\varphi_n, f) \end{bmatrix}$$

此时法方程简化为 $(p_k, p_k)a_k = (f, p_k)$, 即

$$a_k = \frac{(f, p_k)}{(p_k, p_k)} \quad (k = 0, \dots, n)$$

所求的拟合曲线为

$$g_n(x) = a_0 + a_1 p_1(x) + \cdots + a_n p_n(x)$$

- (1) 可以将构造正交多项式族、解法方程、形成拟合多项式穿插进行;
- (2) n 可以事先给定, 或在计算过程中根据误差来定;
- (3) 该方法非常适合编程实现, 只用递推公式, 并且当逼近次数增加时, 只要将相应地增加程序中的循环次数即可。
- (4) 该方法是目前多项式拟合最好的计算方法, 有通用程序。

第7课

数值积分

本章主要讨论如下形式的一元函数积分

$$I(f) = \int_a^b f(x) dx$$

在微积分里，转化为求定积分

$$I(f) = \int_a^b f(x) dx = F(b) - F(a)$$



依据积分中值定理，对于连续函数 $f(x)$ ，
在 $[a, b]$ 内存在一点 ξ ，使得

$$I(f) = \int_a^b f(x) dx = (b - a) f(\xi)$$

在积分区间 $[a, b]$ 上, 取 $n+1$ 个节点 $x_i, i = 0, 1, 2, \dots, n$

$$L_n(x) = \sum_{j=0}^n l_j(x) f(x_j)$$

则有

$$f(x) = L_n(x) + R_n(x)$$

其中,

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} w_{n+1}(x) \quad \text{为插值余项。}$$

于是有:

$$\begin{aligned}\int_a^b f(x)dx &= \int_a^b L_n(x)dx + \int_a^b R_n(x)dx \\ &= \sum_{j=0}^n \left[\int_a^b l_j(x)dx \right] f(x_j) + \int_a^b R(x)dx\end{aligned}$$

取

$$\int_a^b f(x)dx \approx \sum_{k=0}^n f(x_k) \int_a^b l_k(x)dx$$

A_k

求积系数

$$A_k = \int_a^b \prod_{\substack{i=0 \\ i \neq k}}^n \frac{(x - x_i)}{(x_k - x_i)} dx$$

由节点决定,
与 $f(x)$ 无关。

一、Cotes系数

取节点为**等距分布**: $x_i = a + ih$, $h = \frac{b-a}{n}$, $i = 0, 1, \dots, n$

由此构造的插值型求积公式称为**Newton-Cotes公式**, 此时**求积系数**:

$$A_i = \int_{x_0}^{x_n} \prod_{j \neq i} \frac{(x - x_j)}{(x_i - x_j)} dx \quad \text{令 } x = a + th$$

Cotes系数 $C_k^{(n)}$

$$= \int_0^n \prod_{\substack{j=0 \\ j \neq i}}^n \frac{(t - j)h}{(i - j)h} \times h dt = \frac{(b-a)(-1)^{n-i}}{n i!(n-i)!} \int_0^n \prod_{\substack{j=0 \\ j \neq i}}^n (t - j) dt$$

二、Newton-Cotes公式

1、定义：

记
$$C_j^{(n)} = \frac{(-1)^{n-j}}{j!(n-j)!n} \int_0^n \left[\prod_{k=0, k \neq j}^n (t-k) \right] dt$$

则
$$A_j = (b-a)C_j^{(n)}, \quad j = 0, 1, 2, \dots, n$$

求积公式变为

$$\int_a^b f(x) dx \approx (b-a) \sum_{j=0}^n C_j^{(n)} f(x_j)$$

称上式为n阶闭型Newton-Cotes求积公式。



3、代数精度



作为插值型求积公式， n 阶Newton-Cotes公式至少具有 n 次代数精度，而实际的代数精度是否可以进一步提高呢？

定理

当阶数 n 为偶数时，Newton-Cotes公式至少具有 $n+1$ 次代数精度。

$n = 1$:

梯形公式

代数精度 = 1

$$\int_a^b f(x)dx \approx \frac{b-a}{2}[f(a)+f(b)]$$

$n = 2$:

Simpson 公式

代数精度 = 3

$$\int_a^b f(x)dx \approx \frac{b-a}{6}[f(a)+4f(\frac{a+b}{2})+f(b)]$$

$n = 4$: Cotes 公式

$$\int_a^b f(x)dx \approx \frac{b-a}{90}[7f(x_0)+32f(x_1)+12f(x_2)+32f(x_3)+7f(x_4)]$$

代数精度 = 5

复化求积公式

复化梯形公式:

$$\int_a^b f(x)dx \approx \sum_{i=0}^{n-1} \frac{h}{2} [f(x_i) + f(x_{i+1})] = \frac{h}{2} \left[f(a) + 2 \sum_{i=1}^{n-1} f(x_k) + f(b) \right] = \mathbf{T_n}$$

复化 Simpson 公式:

$$\int_a^b f(x)dx \approx \frac{h}{6} \left[f(a) + 4 \sum_{k=0}^{n-1} f(x_{k+\frac{1}{2}}) + 2 \sum_{k=0}^{n-1} f(x_{k+1}) + f(b) \right] = \mathbf{S_n}$$

复化 Cotes公式:

$$\int_a^b f(x)dx \approx \sum_{k=0}^{n-1} \frac{h}{90} [7f(x_k) + 32f(x_{k+\frac{1}{4}}) + 12f(x_{k+\frac{1}{2}}) + 32f(x_{k+\frac{3}{4}}) + 7f(x_{k+1})] = \mathbf{C_n}$$

高斯求积公式

由前面的讨论已经知道，以 $a=x_0 < x_1 < \cdots < x_n=b$ 为节点的 $N-C$ 求积公式的代数精度一般为 n 或 $n+1$ ，这时节点简单地按照闭区间等距的方式确定。

对一个求积公式而言，如果不固定节点的位置，在节点数目不变的情况下，代数精度能否提高，最多能达到多少？

这里高斯型求积公式讨论的就是最高代数精度的求积公式。

例：

求形如 $\int_{-1}^1 f(x)dx \approx A_0 f(x_0) + A_1 f(x_1)$



的两点求积公式。

(1) 用梯形公式（即以 $x_0 = -1$, $x_1 = 1$ 为节点的插值型求积公式）立即可得。

$$\int_{-1}^1 f(x)dx \approx f(-1) + f(1)$$

只具有一次代数
精确度！

(2) 若对求积公式中的四个待定系数 A_0, A_1, x_0, x_1 适当选取,

使求积公式 $\int_a^b f(x)dx \approx A_0 f(x_0) + A_1 f(x_1)$

对 , $f(x) = 1, x, x^2, x^3$ 都准确成立, 则

A_0, A_1, x_0, x_1 需满足如下方程组:

$$\begin{cases} A_0 + A_1 = b - a \\ A_0 x_0 + A_1 x_1 = \frac{1}{2}(b^2 - a^2) \\ A_0 x_0^2 + A_1 x_1^2 = \frac{1}{3}(b^3 - a^3) \\ A_0 x_0^3 + A_1 x_1^3 = \frac{1}{4}(b^4 - a^4) \end{cases}$$



(3) 若用 $n+1$ 点插值积分, 则有:

$$\int_a^b f(x)dx \approx \sum_{k=0}^n A_k f(x_k)$$

若上述积分使 $2(n+1)$ 次以内的被积函数 $f(x)=x^k$, $k=0,1,\dots,2n+1$, 都精确成立, 则有:

$$\left\{ \begin{array}{l} \sum_{k=0}^n A_k = b-a \\ \sum_{k=0}^n A_k x_k = \frac{1}{2}(b^2 - a^2) \\ \sum_{k=0}^n A_k x_k^2 = \frac{1}{3}(b^3 - a^3) \\ \sum_{k=0}^n A_k x_k^3 = \frac{1}{4}(b^4 - a^4) \\ \dots \\ \sum_{k=0}^n A_k x_k^{2n+1} = \frac{1}{2n+2}(b^{2n+2} - a^{2n+2}) \end{array} \right.$$

**2n+2个方程,
2n+2个未知数。**

未知数: $A_0, A_1, \dots, A_n, x_0, x_1, \dots, x_n$

第8章

常微分方程的数值解法

1 概述

本章着重讨论一阶常微分方程初值问题

$$\begin{cases} \frac{dy}{dx} = f(x, y) & a \leq x \leq b \\ y(x_0) = y_0 \end{cases}$$

的数值解法。

常微分方程初值问题的数值解是求上述初值问题的解 $y(x)$ 在区间 $[a, b]$ 中的点列

$x_i = x_{i-1} + h$ ($i = 1, 2, \dots, n$) 上的近似值 y_i ，以下设 h_i 不变，记为 h -步长。

一、欧拉(Euler)法

设节点为 $x_n = x_0 + nh$ ($n = 0, 1, 2, 3 \dots$)，得欧拉方法计算公式为：

$$y_{n+1} = y_n + h \cdot f(x_n, y_n), \quad n = 0, 1, 2, 3, \dots$$

二、梯形法

在式 $y(x_{n+1}) = y(x_n) + \int_{x_n}^{x_{n+1}} f(t, y(t)) dt$

中, 将积分用梯形公式来代替, 则有

$$y(x_{n+1}) = y(x_n) + \frac{h}{2} [f(x_n, y(x_n)) + f(x_{n+1}, y(x_{n+1}))] - \frac{h^3}{12} f''(\eta, y(\eta)) \quad \eta \in (x_n, x_{n+1})$$

从而得到梯形公式:

$$y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, y_{n+1})] \quad n = 0, 1, 2, \dots$$

梯形方法关于 y_{n+1} 是**隐式的**, 而**Euler**方法是显式的。一般情形下不容易从上式解出 y_{n+1} , 因而可将上式与**Euler**公式联合使用

三、Euler预估-校正格式

实用中, 在 h 取得较小时, 用梯形公式计算, 第二式只迭代一次就结束, 得到Euler预估-校正格式:

$$\begin{cases} y_{n+1}^{(0)} = y_n + hf(x_n, y_n) \\ y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1}^{(0)})] (n = 0, 1, 2, \dots) \end{cases}$$

第一式称为预估公式, 第二式称为校正公式。

用泰勒展开法推导Euler预估 - 校正格式的局部截断误差

改写Euler预估 - 校正公式为：

$$\begin{cases} y_{n+1} = y_n + \frac{1}{2}k_1 + \frac{1}{2}k_2 \\ k_1 = hf(x_n, y_n) \\ k_2 = hf(x_n + h, y_n + k_1) \end{cases}$$

在 $y_n = y(x_n)$ 的假定下，

$$k_1 = hf(x_n, y_n) = hf(x_n, y(x_n)) = hy'(x_n)$$

而

$$k_2 = hf(x_n + h, y_n + k_1)$$

$$= hf(x_n + h, y(x_n) + k_1)$$

$$= h \left[f(x_n, y(x_n)) + h \frac{\partial}{\partial x} f(x_n, y(x_n)) + k_1 \frac{\partial}{\partial y} f(x_n, y(x_n)) + O(h^2) \right]$$

$$= hf(x_n, y(x_n)) + h^2 \left[\frac{\partial}{\partial x} f(x_n, y(x_n)) + f(x_n, y(x_n)) \frac{\partial}{\partial y} f(x_n, y(x_n)) \right] + O(h^3)$$

$$= hy'(x_n) + h^2 y''(x_n) + O(h^3)$$

将 k_1, k_2 代入 y_{n+1} , 有

$$\begin{aligned} y_{n+1} &= y_n + \frac{1}{2}[hy'(x_n) + hy'(x_n) + h^2 y''(x_n) + O(h^3)] \\ &= y_n + hy'(x_n) + \frac{1}{2}h^2 y''(x_n) + O(h^3) \end{aligned}$$

而

$$y(x_{n+1}) = y(x_n) + hy'(x_n) + \frac{h^2}{2!} y''(x_n) + O(h^3)$$

因此有

$$R_n = y(x_{n+1}) - y_{n+1} = O(h^3)$$

故Euler预估-校正方法为的局部截断误差阶为 $O(h^3)$ 。

截断误差

定义3: 若一个方法的局部截断误差为 $O(h^{p+1})$,
则称该方法为 p 阶方法, 或称该方法具有 p 阶精度。

Remark: Euler方法是一阶方法, 梯形法和 Euler预估 - 校正法是二阶方法。

3 泰勒展开法与龙格-库塔方法

一、Taylor 方法

- 问题：利用泰勒展开法推导高阶单步的求解常微分方程初值问题的数值方法。
- 从提高截断误差阶的阶数入手。

假定初值问题的解 $y(x)$ 及函数 $f(x, y)$ 是充分光滑的，则：

$$\begin{aligned} y(x_{n+1}) &= y(x_n) + hy'(x_n) + \frac{h^2}{2!} y''(x_n) + \cdots + \frac{h^p}{p!} y^{(p)}(x_n) + O(h^{p+1}) \\ &= y(x_n) + hf(x_n, y(x_n)) + \frac{h^2}{2!} f'(x_n, y(x_n)) + \cdots + \frac{h^p}{p!} f^{(p-1)}(x_n, y(x_n)) + O(h^{p+1}) \end{aligned}$$

当 n 充分小时，略去余项 $O(h^{p+1})$ ，有 p 阶计算公式

$$\begin{cases} y_{n+1} = y_n + hf(x_n, y_n) + \frac{h^2}{2} f'(x_n, y_n) + \cdots + \frac{h^p}{p!} f^{(p-1)}(x_n, y(x_n)) \\ y_0 = \alpha \end{cases}$$

其中，

$$y'_n = f(x_n, y_n)$$

$$y''_n = f_x(x_n, y_n) + f(x_n, y_n) f_y(x_n, y_n)$$

$$y'''_n = [f_{xx} + 2f_{xy}f + f^2 f_{yy} + f_y^2 f + f_x f_y](x_n, y_n)$$

$\vdots$

上式称为 p 阶 Taylor 方法。特别地，当 $p=1$ 时，就是 Euler 公式。当 $p=2$ 时，得二阶 Taylor 方法：

$$y_{n+1} = y_n + hy'_n + \frac{h^2}{2} y''_n = y_n + hf(x_n, y_n) + \frac{h^2}{2} [f'_x + ff'_y]_{(x_n, y_n)}$$

当 Taylor 方法的阶数 p 取的较大时，需计算 $f(x, y)$ 的高阶导数值，计算量较大。特别当 $f(x, y)$ 较复杂时， $y(x)$ 的高阶导数会很复杂。因此 Taylor 方法很少单独使用，但可以用它来启发思路。

二、Runge - Kutta 方法

基本思想：用不同点的函数值作线性组合，构造近似公式，把近似公式和解的Taylor展开比较，使前面的若干项吻合，从而使近似公式达到一定的阶数。一般的显式R-K方法，可以写成

$$\begin{cases} y_{n+1} = y_n + c_1 k_1 + c_2 k_2 + \cdots + c_N k_N \\ k_1 = hf(x_n, y_n) \\ k_2 = hf(x_n + \alpha_2 h, y_n + \beta_{21} k_1) \\ k_3 = hf(x_n + \alpha_3 h, y_n + \beta_{31} k_1 + \beta_{32} k_2) \\ \vdots \\ k_N = hf(x_n + \alpha_N h, y_n + \beta_{N1} k_1 + \beta_{N2} k_2 + \cdots + \beta_{N,N-1} k_{N-1}) \end{cases}$$

上述公式叫做 N 级的Runge-Kutta方法，其局部截断误差为 $O(h^{N+1})$ 。

其中 $f_n, f'_n, f''_n, \dots$ 表示

$$y'(x_n) = f(x_n, y_n), y''(x_n), y'''(x_n), \dots$$

显然，Euler法是一级一阶R-K方法。

下面以二级R-K公式为例，来说明R-K方法的推导过程。

4 线性多步法

线性多步法的**基本思想**：如果充分利用前面多步的信息来预测 y_{n+k} ，则可以期望获得较高的精度。

前面的**R-K**方法是增加一些非节点处的函数值的计算来提高单步法的精度的，这样使计算量增加了许多。本节介绍多步法，是在不过分增加计算量的情况下取得较高的计算精度。

线性多步法公式的**构造**一般用两种方法，即Taylor展开法与数值积分法。

线性多步法的一般形式

$$y_{n+1} = \alpha_0 y_n + \alpha_1 y_{n-1} + \cdots + \alpha_r y_{n-r} + \\ h(\beta_{-1} f_{n+1} + \beta_0 f_n + \beta_1 f_{n-1} + \cdots + \beta_r f_{n-r})$$

式中 $f_{n-k} = f(x_{n-k}, y_{n-k}) (k = -1, 0, 1, \cdots, r)$, α_i, β_j 都为实数, 且 $|\alpha_r| + |\beta_r| \neq 0$ 。当 $\beta_{-1} \neq 0$ 时上式为隐式方法, 当 $\beta_{-1} = 0$

时, 上式为显示方法。由于求 y_{n+1} 用到前面 $y_n, y_{n-1}, \dots, y_{n-r}$ 等 $r+1$ 个值, 且关于 y_{n-j} 和 $f_{n-j} (j=0, 1, 2, \dots, r)$ 都是线性的, 因此称上式为线性 $r+1$ 步方法。

1. 阿达姆斯 (Adams) 外插公式

在(1)式中取 $k=0$ ，并选择 $x_n, x_{n-1}, x_{n-2}, x_{n-3}$ 作为插值节点，作函数 $F(x)$ 的三次插值多项式：

$$L_3(x) = \sum_{i=0}^3 \left(\prod_{\substack{j=0 \\ j \neq i}}^3 \frac{x - x_{n-j}}{x_{n-i} - x_{n-j}} \right) F(x_{n-i})$$

其插值余项为：

$$R_3(x) = \frac{1}{4!} F^{(4)}(\xi)(x - x_n)(x - x_{n-1})(x - x_{n-2})(x - x_{n-3})$$

$$x_{n-3} \leq \xi \leq x_n$$

从而得到线性四步Adams显式公式:

$$y_{n+1} = y_n + \frac{h}{24} [55f(x_n, y_n) - 59f(x_{n-1}, y_{n-1}) + 37f(x_{n-2}, y_{n-2}) - 9f(x_{n-3}, y_{n-3})] \quad (n = 3, 4, 5, \dots)$$

因为插值多项式 $L_3(x)$ 是在 $[x_{n-3}, x_n]$ 上作出的, 而积分区间为 $[x_n, x_{n+1}]$, 故上式称为Adams外插公式。

2. 阿达姆斯 (Adams) 内插公式

若在(1)式中取 $k=2$ ，并选择 $x_{n+1}, x_n, x_{n-1}, x_{n-2}$ 作为插值节点，作函数 $F(x)$ 的三次插值多项式。类似于上面的外插公式，有

$$y_{n+1} = y_n + \frac{h}{24} [9f_{n+1} + 19f_n - 5f_{n-1} + f_{n-2}]$$

$$R_n = -\frac{19}{720} h^5 y^{(5)}(\eta_n)$$

该公式也称为Adams内插公式，为三步隐式方法。



第10章

线性搜索与排序算法

教师：肖依永 | 刘杰 | 周晟瀚
可靠性与系统工程学院

本章内容提纲

1 线性搜索算法

2 排序算法

3 算法的复杂度



第11章

网络与图相关算法

教师：肖依永 | 刘杰 | 周晟瀚
可靠性与系统工程学院

本章内容提纲

- 1 树的遍历算法
- 2 图的遍历（深度优先）
- 3 图的遍历（广度优先）
- 4 最短路径算法



预祝大家考试顺利！